1 Linear Regression (OLS / Ridge / Lasso) - dokumentacja modelu

1.1 Nagranie wideo (YouTube)

Wideo prezentujące projekt oraz sposób uruchomienia i demonstrację działania:

- https://www.youtube.com/watch?v=gqYQ3Df0xIU

1.2 Cel modelu

Model liniowy służy do prognozy **zwrotu BTC na następny dzień** (1-step ahead):

- `ret_btc_next = pct_change(close_btc).shift(-1)`

  Czyli w dniu t używamy cech z dnia t, aby przewidzieć zwrot w dniu $t+1$.

1.3 Dane i przygotowanie datasetu

1.3.1 Źródło danych

- `backend/data/historical_data.parquet`

  Po wczytaniu dane są sortowane chronologicznie po `open_time` (jeśli kolumna istnieje).

1.3.2 Budowa targetu

W kodzie target jest tworzony następująco:

- `ret_btc = close_btc.pct_change()`
- `ret_btc_next = ret_btc.shift(-1)`

  Następnie usuwane są wiersze z brakami w cechach lub w target (`dropna`).

1.4 Cechy wejściowe (FEATURE_COLUMNS)

W tym modelu używamy **surowych poziomów** (OHLC, wolumen, liczba transakcji, indeks SPX oraz makro).

Ceny (OHLC) dla krypto:

- `open_btc`, `high_btc`, `low_btc`, `close_btc`
- `open_eth`, `high_eth`, `low_eth`, `close_eth`
- `open_bnb`, `high_bnb`, `low_bnb`, `close_bnb`
- `open_xrp`, `high_xrp`, `low_xrp`, `close_xrp`

Wolumen i liczba transakcji:

- `volume_btc`, `volume_eth`, `volume_bnb`, `volume_xrp`
- `num_trades_btc`, `num_trades_eth`, `num_trades_bnb`, `num_trades_xrp`

Indeks SPX:

- `open_spx`, `high_spx`, `low_spx`, `close_spx`, `volume_spx`

Makro:

- `gdp`, `unrate`

Target:

- `ret_btc_next`

1.5 Split danych (train/test)

Podział jest chronologiczny, bez losowego mieszania:

- `test_size = 0.2`
- `shuffle = False`

Dla uruchomionego runu:

- `n_train = 1680`
- `n_test = 420`

To utrzymuje realistyczny scenariusz predykcji w szeregach czasowych (trenujemy na przeszłości i testujemy na przyszłości).

1.6 Pipeline i skalowanie

Model jest trenowany jako `sklearn.pipeline.Pipeline`:

1. `StandardScaler()`
2. regresor liniowy: `LinearRegression` / `Ridge` / `Lasso`

Skalowanie jest szczególnie istotne dla modeli z regularyzacją (Ridge/Lasso), bo współczynniki kary zależą od skali cech.

1.7 Warianty modelu

Skrypt obsługuje 3 tryby (`-model-type`):

1.7.1 1) OLS (LinearRegression)

- klasyczna regresja najmniejszych kwadratów bez regularyzacji

1.7.2 2) Ridge

- regresja z karą L2: `Ridge(alpha=alpha)`
- stabilizuje współczynniki i zmniejsza wariancję, zwykle pomaga przy współliniowości cech

1.7.3 3) Lasso

- regresja z karą L1: `Lasso(alpha=alpha)`
- może zerować część wag (selekcja cech), co bywa korzystne przy dużej liczbie skorelowanych sygnałów

---

1.8 Strojenie hiperparametrów (Lasso)

Jeśli `-model-type lasso`, wykonywane jest proste strojenie `alpha` na zbiorze testowym (chronologicznym):

Testowane wartości:

- `[0.0001, 0.001, 0.005, 0.01, 0.05, 0.1, 0.2, 0.5, 1.0]`

Wybór "best":

- minimalne `MAE` na zbiorze testowym

Z logów:

- **Best alpha:** `0.005`
- **MAE** = `0.016855`
- **RMSE** = `0.023352`

1.9 Metryki

Raportowane metryki na zbiorze testowym:

- `MAE = mean_absolute_error(y_test, y_pred)`
- `RMSE = sqrt(mean_squared_error(y_test, y_pred))`

1.10 Wyniki eksperymentów (z logów)

1.10.1 OLS (LinearRegression)

- **MAE:** `0.043481953958960734`
- **RMSE:** `0.0649079753374987`
- `n_train=1680`, `n_test=420`

W tej konfiguracji model liniowy bez regularyzacji nie generalizuje dobrze na test-set.

1.10.2 Lasso (z tuningiem alpha)

- **MAE:** `0.01685521013312673`
- **RMSE:** `0.0233521064909458`
- najlepsze `alpha = 0.005`

Widać, że regularyzacja L1 znacząco poprawia wynik względem OLS.

1.11 Artefakty i zapis modelu

Model jest zapisywany do:

- `backend/data/linear_regression_btc.pkl`

Format zapisu (`joblib.dump`) zawiera słownik:

- `model`: pipeline (scaler + regressor)
- `features`: lista `FEATURE_COLUMNS`
- `target`: `ret_btc_next`
- `target_column_in_df`: `ret_btc_next`

To umożliwia spójne odtworzenie inferencji (te same cechy w tej samej kolejności + ten sam scaler).

2 Random Forest

2.1 Zbiór danych

Rozpoczynając pracę nad random forestem korzystaliśmy z danych historycznych, które zawierały następujące wartości:

2.1.1 Ceny otwarte, najwyższe, najniższe, zamknięte

- `open_btc`, `open_eth`, `open_bnb`, `open_xrp`, `open_spx`
- `high_btc`, `high_eth`, `high_bnb`, `high_xrp`, `high_spx`
- `low_btc`, `low_eth`, `low_bnb`, `low_xrp`, `low_spx`
- `close_btc`, `close_eth`, `close_bnb`, `close_xrp`, `close_spx`

2.1.2 Wolumen i liczba transakcji

- `volume_btc`, `volume_eth`, `volume_bnb`, `volume_xrp`, `volume_spx`
- `num_trades_btc`, `num_trades_eth`, `num_trades_bnb`, `num_trades_xrp`, `num_trades_spx`

2.1.3 Indeksy globalne

- `gdp`
- `unrate`

2.2 Budowa modelu

Rozpoczynając pracę nad modelem, zdecydowaliśmy, że najważniejszymi parametrami naszego modelu będą:

- `max_depth` - ogranicza głębokość drzewa
- `min_samples_leaf` - minimalna liczba próbek w liściu
- `max_features` - liczba cech, które bierze pod uwagę pojedyncze drzewo
- `n_estimators` - liczba drzew w lesie

- `max_samples` - liczba próbek, na których uczy się każde drzewo
- `criterion` - funkcja oceniająca jakość podziału

Dlatego właśnie to optymalizacją tych parametrów zajęliśmy się w pierwszej kolejności.

2.3 Pierwsze wnioski i problemy

Wstępna optymalizacja metodą **Grid Search** wykazała niepokojące tendencje. Model dążył do tworzenia skrajnie płytkich lasów, co sugerowało wysoki poziom szumu w danych.

```
=== BEST MODEL FROM GRID SEARCH ===
Best hyperparameters:
  max_depth: 3
  min_samples_leaf: 300
  max_features: log2
  n_estimators: 50
  max_samples: 0.5
```

Zaniepokoiły nas następujące rzeczy:

- **Płytkie drzewa** — Drzewa o maksymalnej głębokości 3 (`max_depth: 3`), nie pozwalają na wykrycie złożonych zależności i reguł między danymi.
- **Mało drzew** — Większa liczba drzew (`n_estimators: 50`) nie przynosi poprawy, co sugeruje, że dane są mocno zaszumione.
- **Duża liczba próbek na liściach** — Wysoka liczba próbek (`min_samples_leaf: 300`) sprawia, że las mocno uśrednia predykcje i nie wykrywa nowych, krótkoterminowych trendów.

W związku z tym, zdecydowaliśmy, że problem stanowią wykorzystywane przez nas dane, które wprowadzają szum do naszego modelu.

2.4 Przetworzenie i dodanie nowych cech

Aby wyeliminować szum i dostarczyć modelowi bardziej czytelne sygnały, dokonaliśmy transformacji danych, wprowadzając nowe grupy cech:

2.4.1 Zwroty z cen `ret_`

- `ret_close_*` - dzienna zmiana ceny zamknięcia danego rynku (np. BTC, ETH, SPX) wyrażona jako różnica między dniem bieżącym, a poprzednim.
- `ret_hl_*` - analogiczny wskaźnik liczony dla ceny uśrednionej z danego dnia (średnia z wartości high i low).

2.4.2 Aktywność na rynku `dlog`

- `dlog_volume_sum` - zmiana łącznego wolumenu obrotu na wszystkich rynkach w skali logarytmicznej (dzień do dnia).
- `dlog_num_trades_sum` - odpowiednik powyższej miary dla łącznej liczby transakcji na rynku kryptowalut.

2.4.3 Wartości wygładzone `ewm`

Czyli trend w aktywności rynku zamiast dziennego szumu.

- `ewm_ret_close_*` i `ewm_ret_hl2_*` - wykładniczo ważona średnia zwrotów cen, gdzie nowsze obserwacje mają większą wagę niż starsze (lepsze odwzorowanie aktualnego trendu).
- `ewm_dlog_volume_sum_*` i `ewm_dlog_num_trades_sum_*` - identyczna metoda wygładzania zastosowana dla zmian wolumenu i liczby transakcji.

2.4.4 Zmienność `roll_std`

- `roll_std_ret_close_btc_*` - miara zmienności rynku, liczona jako odchylenie standardowe zwrotów BTC w ruchomym oknie czasowym (np. 7, 21 dni).

2.4.5 Makro `gdp`, `unrate`

- `gdp_lag1`, `gdp_growth`, `unrate_lag1`, `unrate_change` - poziomy i zmiany PKB oraz bezrobocia z poprzednich okresów. Używamy wartości opóźnionych (lag), ponieważ dane te publikowane są rzadziej. Dzięki temu chronimy model przed wyciekiem danych z przyszłości (data leakage).

2.5 Analiza shap

Za pomocą narzędzia SHAP przyjrzeliśmy się poszczególnym cechom naszego modelu.

Na poniższym wykresie przedstawiono 20 cech, które mają największy wpływ na predykcję drzew. Wykres składa się głównie z pionowych kresek - jest to kwestia działania drzew decyzyjnych w modelu Random Forest, które grupują dane i każda grupa dostaje tę samą wartość SHAP. Kilka zmiennych pojawia się **jako pojedyncza prosta pionowa linia** (np. `open_bnb` i `close_bnb` na samej górze wykresu). To wskazuje, że te niezależnie od tego, czy ich wartości są niskie (niebieski) czy wysokie (czerwony), model nie wie co z nimi zrobić i traktuje je tak samo. Wprowadzają szum i powinny zostać wyeliminowane.

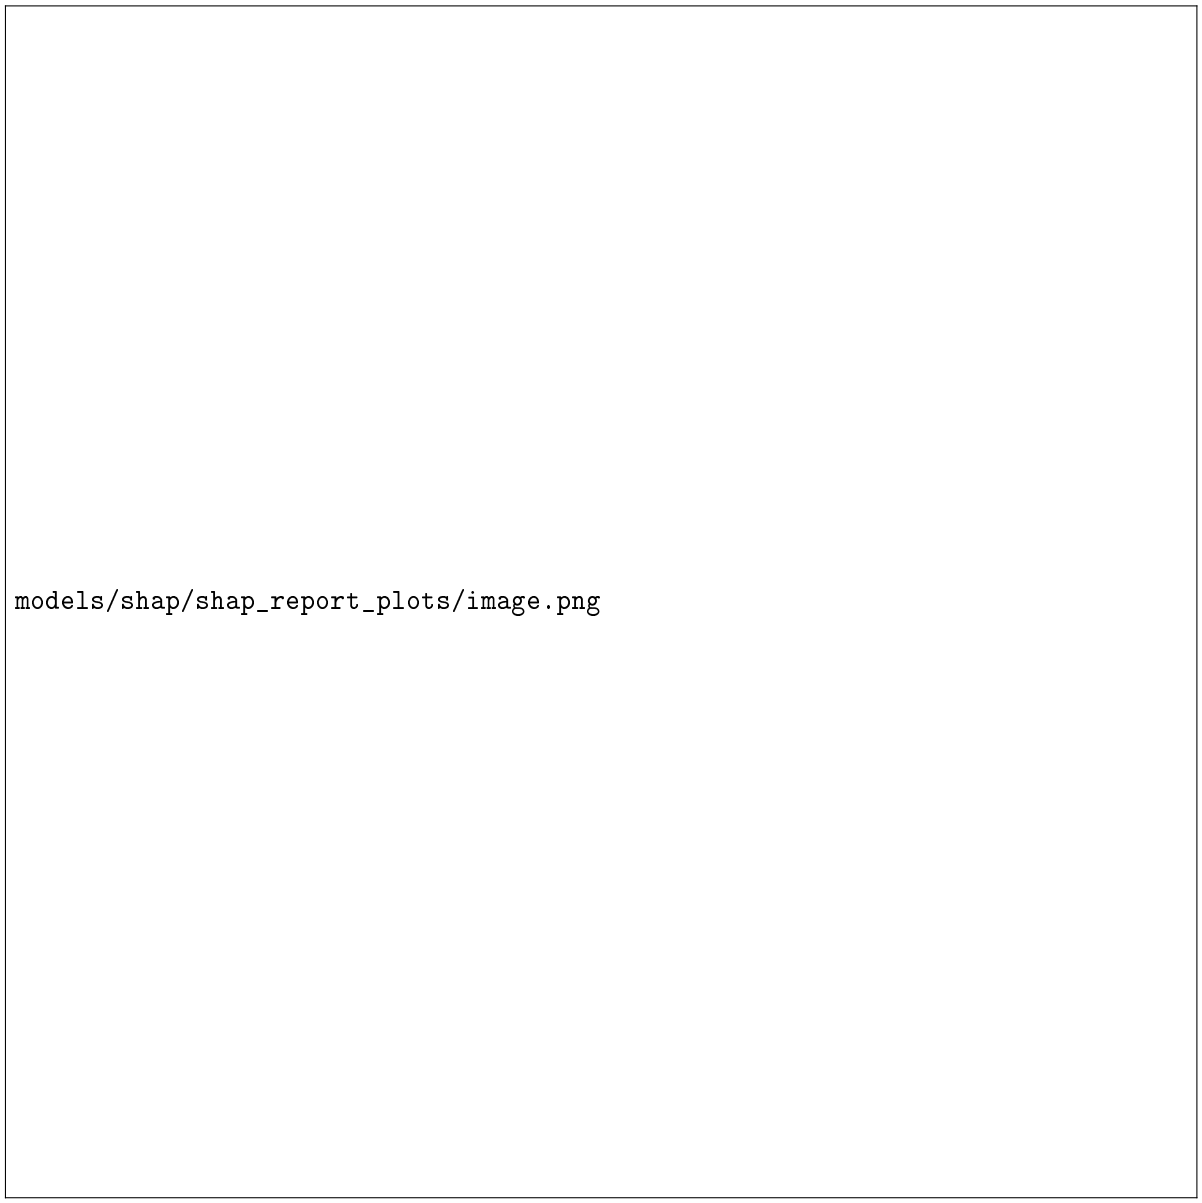

Rysunek 2: *
All features shap summary

W pierwszej kolejności rzucała się w oczy konieczność eliminacji surowych danych giełdowych, takich jak `open_{asset}`, `high_{asset}`, `low_{asset}`, `close_{asset}`, `volume_{asset}`, `num_trades_{asset}`. Zostały one zamienione lepszymi cechami, obrazującymi zmianę wartości, a nie surowe poziomy.

Kolejnymi cechami, które nie okazały się produktywne są dane makroekonomiczne, takie jak `gdp`, `unrate`, `unrate_lag1`.

Po eliminacji tych cech, tak prezentuje się wykres podsumowania SHAP:

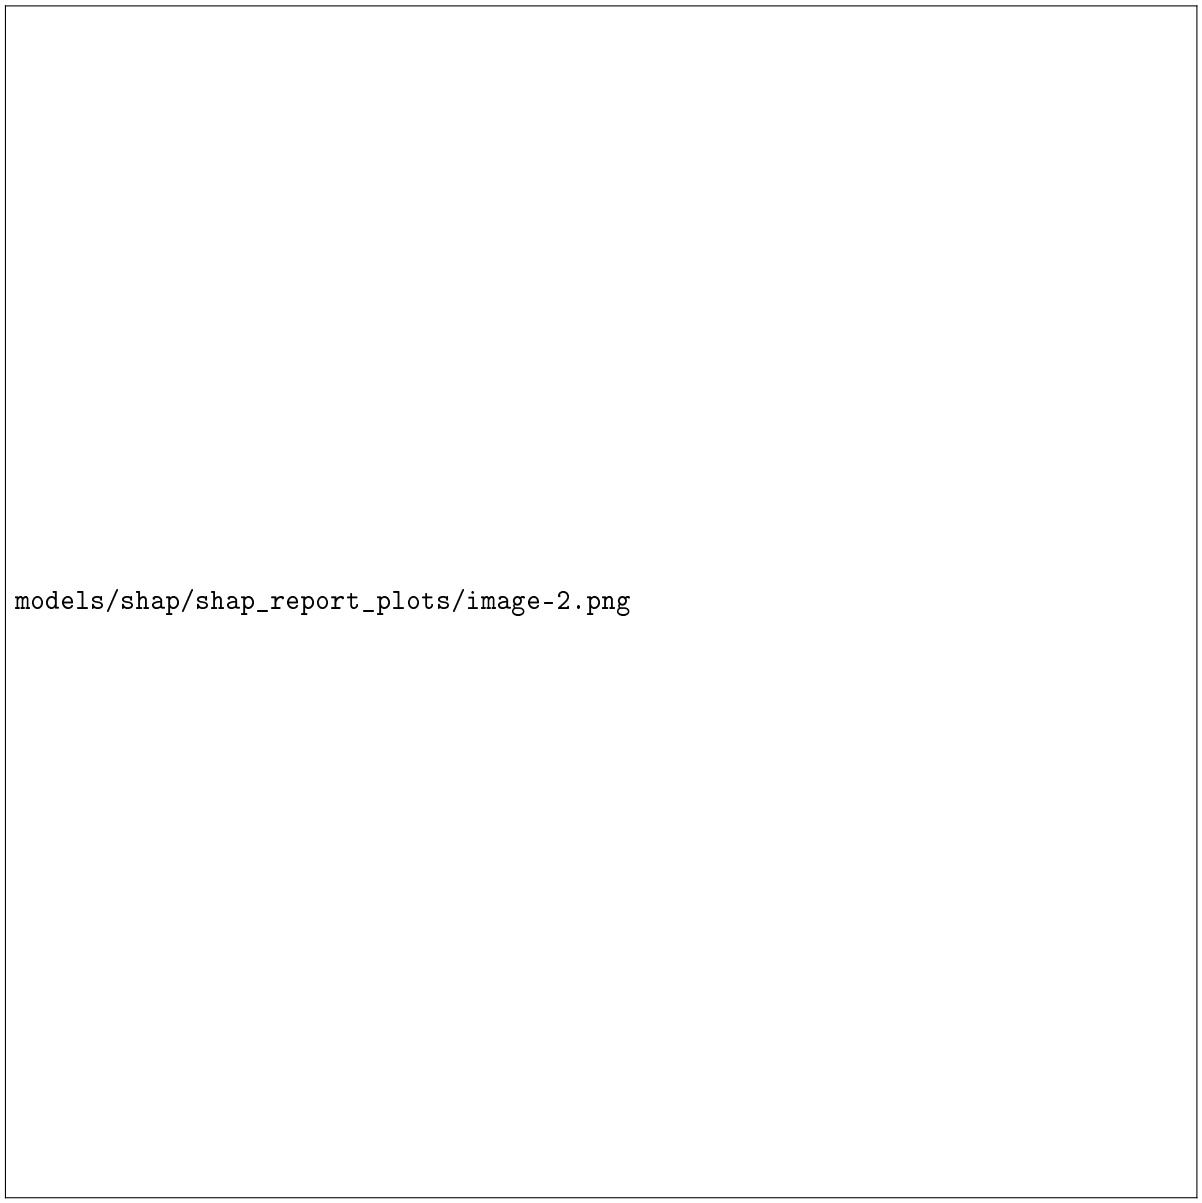

Rysunek 4: *
Third shap summary

2.6 Ostateczna wersja modelu

Finalnie postanowiliśmy skupić się na danych opisujących **zmianę** cen (`ret_close_` czy `ret_hl2_`), zamiast surowych wartości. Wykorzystaliśmy także cechy wygładzone (`ewm_ret_close_` czy `ewm_ret_hl2_`) i zsumowane dla różnych walut (`dlog_num_trades_sum`, `dlog_volume_sum`). Ostateczny model uzyskał na zbiorze testowym wynik `MAE` ≈ 0.01679 oraz `RMSE` ≈ 0.02330.

Lista cech:

- `ret_close_bnb`,
- `ret_close_btc`,
- `ret_close_eth`,
- `ret_close_spx`,
- `ret_close_xrp`,

- ret_hl2_bnb,
- ret_hl2_btc,
- ret_hl2_eth,
- ret_hl2_spx,
- ret_hl2_xrp,
- ewm_dlog_num_trades_sum_s7,
- ewm_dlog_volume_sum_s7,
- ewm_ret_close_bnb_s7,
- ewm_ret_close_btc_s7,
- ewm_ret_close_eth_s7,
- ewm_ret_close_spx_s7,
- ewm_ret_close_xrp_s7,
- ewm_ret_hl2_bnb_s7,
- ewm_ret_hl2_btc_s7,
- ewm_ret_hl2_eth_s7,
- ewm_ret_hl2_spx_s7,
- ewm_ret_hl2_xrp_s7,
- dlog_num_trades_sum,
- dlog_volume_sum,
- gdp_growth,
- unrate_change,
- ret_btc

A także parametrów:

```
n_estimators=100,
max_depth=5,
min_samples_leaf=200,
max_features="log2",
max_samples=0.3,
```

3 LSTM (Long Short-Term Memory) - dokumentacja modelu

3.1 Cel modelu

Model LSTM prognozuje **1-step ahead log-return BTC na następny dzień**:

- `ret_btc_next = log(close_btc).diff().shift(-1)`

Nie przewidujemy poziomu ceny (niestacjonarnego), tylko **zwrot**. Na etapie inferencji zwrot przeliczamy na poziom ceny:

- `pred_close = last_close * exp(pred_ret)`

3.2 Dane i cechy wejściowe

3.2.1 Źródło danych

- `backend/data/historical_data.parquet`

Zawiera szeregi dla:

- krypto: BTC, ETH, BNB, XRP
- indeks: SPX
- makro: GDP, UNRATE

3.2.2 Feature engineering (ten sam kierunek co RF/TFT)

Celem FE jest dostarczenie sygnałów opisujących **zmiany i trend**, zamiast surowych poziomów.

1. Zwroty cen (`ret_`)
   - `ret_close_*` - log-return close
   - `ret_hl2_*` - log-return `hl2 = (high + low)/2`
2. Aktywność rynku (`dlog`)
   - `volume_sum` (suma wolumenów dla BTC/ETH/BNB/XRP/SPX)
   - `num_trades_sum` (suma liczby transakcji dla BTC/ETH/BNB/XRP)
   - `dlog_volume_sum = log1p(volume_sum).diff()`
   - `dlog_num_trades_sum = log1p(num_trades_sum).diff()`
3. Wygładzanie trendu (`ewm`, span=7)
   - `ewm_ret_close_*_s7`, `ewm_ret_hl2_*_s7`
   - `ewm_dlog_volume_sum_s7`, `ewm_dlog_num_trades_sum_s7`

   EWM liczone na serii opóźnionej (`shift=1`), żeby cechy w dniu t korzystały wyłącznie z historii do *t-1*.
4. Makro (bez wycieku danych)
   - `gdp_growth = (gdp.shift(1)).pct_change()`
   - `unrate_change = unrate.shift(1) - unrate.shift(2)`

3.3 Zestaw cech używany w modelu (26)

Model używa 26 kolumn (FEATURE_COLUMNS):

- `ret_close_{bnb, btc, eth, spx, xrp}`
- `ret_hl2_{bnb, btc, eth, spx, xrp}`
- `ewm_ret_close_{bnb, btc, eth, spx, xrp}_s7`
- `ewm_ret_hl2_{bnb, btc, eth, spx, xrp}_s7`
- `dlog_volume_sum`, `dlog_num_trades_sum`

- `ewm_dlog_volume_sum_s7`, `ewm_dlog_num_trades_sum_s7`
- `gdp_growth`, `unrate_change`

Target:

- `ret_btc_next`

3.4 Budowa sekwencji (lookback window)

LSTM dostaje sekwencje o długości `lookback = L`:

- `X[i] = df[i : i+L, feature_cols] -> shape (L, n_features)`
- `y[i] = df[i+L-1, ret_btc_next] (target przypisany do końca okna)`

Interpretacja:

- "ostatnie **L dni** cech" -> "zwrot **jutro**".

3.5 Split i preprocessing (bez leakage)

1. Sortowanie i czyszczenie
   - dane sortowane po `open_time`
   - usuwane wiersze z brakami po FE + budowie targetu
2. Podział train/val
   - split chronologiczny: `train = [:split_idx]`, `val = [split_idx:]`
   - brak shuffla (zachowujemy realizm szeregów czasowych)
3. Skalowanie cech (StandardScaler)
   - `mean/std` liczone **wyłącznie na train**
   - transformacja stosowana na train i val
4. Skalowanie targetu (włączone w finalnym runie)
   - `ret_btc_next` standaryzowany na train (`z-score`)
   - predykcja jest odskalowywana do skali zwrotu przed przeliczeniem na cenę

3.6 Architektura

3.6.1 Warstwa sekwencyjna

- `nn.LSTM(input_size=n_features, hidden_size=hidden_size, num_layers=num_layers, batch_first`
- dropout w LSTM aktywny tylko dla `num_layers > 1`

3.6.2 Głowica regresyjna

- bierzemy wektor z ostatniego kroku: `out[:, -1, :]`
- MLP: `Linear -> ReLU -> Dropout -> Linear(..., 1)`
- wynik: pojedyncza wartość `pred_ret_btc_next`

3.7 Trening (najważniejsze elementy)

- loss: `L1Loss` (raportujemy MAE)
- optymalizator: `AdamW(lr, weight_decay)`
- scheduler: `ReduceLROnPlateau` na `val_mae`
- gradient clipping: `grad_clip = 1.0`
- early stopping: zatrzymanie po `patience` epokach bez poprawy `val_mae`
- zapisywany jest najlepszy checkpoint (wg `val_mae`)

3.8 Ostateczna wersja modelu (MAE, hiperparametry, wnioski)

3.8.1 Konfiguracja finalnego runu

- `lookback = 96`, `seed = 314`
- `hidden_size = 64`, `num_layers = 2`, `dropout = 0.15`
- `batch_size = 64`
- `lr = 8e-4`, `weight_decay = 5e-4`
- `epochs = 100`, `patience = 15`
- `target_scaling = True`
- `n_features = 26`

3.8.2 Wynik na walidacji (MAE)

- **Best val MAE:** `0.015704`

3.8.3 Interpretacja przebiegu uczenia

- walidacja poprawia się głównie na początku treningu, a najlepszy wynik pojawia się wcześnie
- później widoczna jest stabilizacja/pogorszenie `val_mae`, mimo dalszego spadku `train_mae`

W praktyce oznacza to, że model szybko "wyciąga" dostępny sygnał, a dalsze uczenie zwiększa dopasowanie do danych treningowych bez poprawy uogólniania.

3.9 Uzasadnienie doboru hiperparametrów

- `lookback=96`: kompromis między zbyt krótkim kontekstem (szum) a zbyt długim (wyższe ryzyko overfitu i niestabilności).
- `hidden_size=64`: umiarkowana pojemność; wystarczająca do modelowania relacji między wieloma cechami, bez nadmiernego "rozrostu" modelu.
- `num_layers=2`: daje większą ekspresję niż 1 warstwa, a jednocześnie jest bezpieczniejsze niż głębsze RNN w noisy danych.
- `dropout=0.15` + `weight_decay=5e-4`: regularizacja dobrana pod obserwację, że najlepsze `val_mae` pojawia się wcześnie (czyli potrzebujemy kontroli nad overfitem).
- `lr=8e-4` + `AdamW`: szybkie zejście z błędem w pierwszych epokach przy stabilnym treningu; scheduler dodatkowo "hamuje", gdy walidacja przestaje się poprawiać.
- `target_scaling=True` + `grad_clip=1.0`: stabilizacja treningu (skalowanie amplitudy celu + kontrola gradientów w LSTM).

4 TFT (Temporal Fusion Transformer) - eksperymenty i uzasadnienie hiperparametrów

4.1 Cel modelu

Model TFT trenujemy do prognozy ceny close bitcoina 1 krok do przodu. Pipeline jest przygotowany pod rolling backtest na zbiorze testowym, z metrykami:

- MAE
- RMSE

Dodatkowo porównujemy go do naiwniego baseline.

4.2 Dane i cechy

4.2.1 Źródło danych

Dataset zawiera:

- kolumnę czasu: `open_time`
- target: `TARGET_COLUMN`
- cechy bazowe: `FEATURE_COLUMNS`

4.2.2 Feature engineering: cechy kalendarzowe cykliczne

Do danych dodawane są cechy czasowe (cykliczne, sin/cos):

- dzień tygodnia (`dow_sin`, `dow_cos`)
- tydzień roku (`week_sin`, `week_cos`)

To jest kluczowe, bo:

- model dostaje sygnał sezonowości bez numerków (np. `week=1..52`),
- sin/cos zachowuje cykliczność (np. tydzień 52 jest blisko tygodnia 1).

4.2.3 Time index w Darts

Zamiast timestampów, budowany jest indeks kroków:

- `_t = 0..N-1`

I dopiero na tym powstają szeregi czasowe Darts:

- `target: TimeSeries(value_cols=[TARGET_COLUMN])`
- `past_covariates: TimeSeries(value_cols=FEATURE_COLUMNS + time_features)`

To jest w porządku, bo model i tak działa sekwencyjnie, a prawdziwy czas jest zakodowany w cechach kalendarzowych + względnym indeksie.

4.3 Podział danych

4.3.1 Train/Test

Split jest prosty, chronologiczny:

- `split_idx = int(n * (1 - test_size))`
- train = `[:split_idx]`
- test = `[split_idx:]`

4.3.2 Train/Val wewnątrz train

Walidacja jest wycinana z końcówki traina (`val_ratio`), z zabezpieczeniami na minimalne długości:

- val ma minimum `max(10, output_chunk_length + 2)`
- train musi mieć minimum `input_chunk_length + output_chunk_length + 5`

To jest ważne, bo TFT wymaga sensownego kontekstu sekwencji.

4.4 Skalowanie

Skalowanie jest robione tylko na train (to poprawnie unika data leakage):

- osobny scaler dla `target`
- osobny scaler dla `past_covariates`

W praktyce:

- model trenuje na znormalizowanych seriach,
- metryki liczone są po inverse_transform, więc MAE/RMSE są w skali oryginalnej.

4.5 Model

4.5.1 Konstrukcja

Używany jest `darts.models.TFTModel` z:

- `add_relative_index=True`
- `loss_fn = nn.MSELoss()`
- `likelihood=None` (czyli deterministycznie, bez probabilistyki)
- trener Lightning na CPU (`accelerator="cpu"`, `devices=1`)
- early stopping: monitor `val_loss`

4.5.2 Dlaczego `add_relative_index=True` pomaga?

Bo przy indeksie `_t=0..N-1` model dostaje dodatkową informację o pozycji w oknie wejściowym. To poprawia stabilność uczenia, szczególnie gdy:

- sygnał w cechach jest podobny w różnych fragmentach historii,
- chcemy, żeby model odróżniał dawne vs świeższe punkty w kontekście.

4.6 Ewaluacja: rolling 1-step ahead (historyczne prognozy)

Test liczony jest metodą zbliżoną do rzeczywistego przewidywania:

- start od `max(split_idx, input_chunk_length, len(target) - max_points)`
- `forecast_horizon=1`
- `stride = eval_stride`
- `retrain=False`
- `last_points_only=True`

To daje realistyczny obraz jakości w symulacji działania produkcyjnego.

4.7 Tryby eksperymentów

4.7.1 Single run

Trening jednego zestawu hiperparametrów i zapis artefaktów:

- `tft_model` (Darts save)
- `scalers.joblib`
- `metadata.json` z configiem i listą covariatów

4.7.2 Grid search

Dwa tryby:

- `GRID_MODE="full"`: pełna siatka kombinacji (z constraintem `hidden_size % num_attention_heads == 0`)
- `GRID_MODE="random"`: losowe próby unikalnych kombinacji

Kryterium wyboru best:

- najmniejsze MAE na rolling teście

4.8 Przestrzeń przeszukiwania (SearchSpace)

Testowane były:

- `input_chunk_length`: (30, 60, 90)
- `hidden_size`: (16, 96)
- `lstm_layers`: (2,)
- `num_attention_heads`: (1, 4)
- `dropout`: (0.0, 0.2)
- `lr`: (3e-4, 1e-3)
- `batch_size`: (64,)

Constraint:

- `hidden_size % num_attention_heads == 0` czyli (16, 4) i (96, 4) są ok, ale np. (16, 3) byłoby odrzucone.

4.9 Uzasadnienie: dlaczego wybrane hiperparametry zadziałały najlepiej

4.9.1 1) `output_chunk_length = 1` (stałe)

To ma sens, bo cała ewaluacja i pipeline są zrobione pod jednopunktową predykcję. Dla returnów często najlepsza jakość jest właśnie dla 1 kroku, bo błędy nie kumulują się jak w multi-step.

4.9.2 2) `input_chunk_length` w zakresie 30-90

To jest balans między:

- za krótko (np. `< 20-30`): model nie widzi kontekstu, a attention/LSTM nie mają z czego wyciągać wzorców
- za długo (np. dużo powyżej 90): dla returnów zwykle nie ma stabilnych zależności dalekiego zasięgu, a długi kontekst podnosi wariancję i ułatwia overfit

4.9.3 3) `hidden_size` = 16 vs 96 (mały vs większy model)

To wprost kontroluje pojemność. Im mniejszy hidden_size, tym większa odporność na szum i mniejsze dopasowanie.

4.9.4 4) `lstm_layers = 2`

Dwie warstwy LSTM w TFT powinny dawać rozsądną reprezentację sekwencji, z niewielkim ryzykiem overfitu.

4.9.5 5) `num_attention_heads` = 1 lub 4

Heads kontrolują, ile różnych perspektyw attention może utrzymać.

- 1 head: prostszy model, mniejsze ryzyko overfitu, często lepszy gdy dane są noisy.
- 4 heads: model może równolegle patrzeć na różne fragmenty kontekstu (np. inne cechy/okresy).

4.9.6 6) `dropout` = 0.0 albo 0.2

Im bardziej skomplikowany model, tym większy dropout ma sens.

4.9.7 7) `lr` = 3e-4 albo 1e-3

4.9.8 8) `batch_size = 64`

4.10 Dlaczego te ustawienia najlepiej zadziałały?

W tym problemie największym wrogiem jest overfit i udawana przewidywalność. Sprawdziłem w zasadzie model mniejszy i większy. Liczyłem na to, że mniejszy, prostszy model lepiej zgeneralizuje i nie będzie miał zbyt dużego overfitu i chyba się to nawet udało - w końcu tft miał najlepszy wynik ze wszystkich naszych modeli.